# Introdução à Scikit-learn

Thiago Teixeira Santos <thiago.santos@embrapa.br>

17 de novembro de 2017

# 1 Introdução

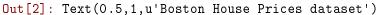
- Há um conjunto de técnicas de aprendizado e inferência que inclui
  - Regressão Linear
  - Regressão Logística
  - Clustering (diversos algoritmos)
  - Máquinas de suporte vetorial
  - Processos Gaussianos
  - PCA/LDA
  - etc.
- Tais técnicas apresentam nomes diferentes em comunidades diferentes
  - Cientistas da Computação e engenheiros chamam de aprendizado de máquina
  - Economistas chamam de econometria
  - Estatísticos de aprendizado estatístico de padrões
  - Bioinformatas de bioestatística

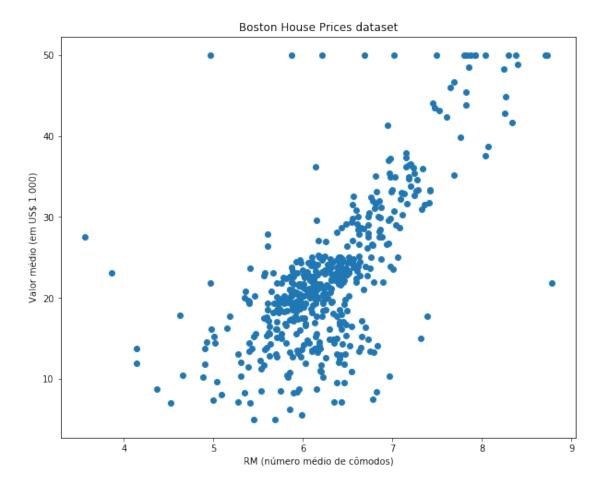
### 1.1 Qual é a tarefa em questão?

- Essas técnicas tentam resolver um problema de aprendizado: dadas n amostras de dados, predizer as propriedades de dados não observados
- Problemas de aprendizado são geralmente dividos em 2 casos:
  - Aprendizado supervisionado no qual as amostras apresentam informação extra sobre a propriedade a ser prevista
    - \* Regressão a propriedade a ser prevista é um valor contínuo
      - · *Exemplo* o *preço* de uma casa a partir de dados de localização, cômodos, vizinhança, etc.
    - \* Classificação a propriedade a ser prevista é uma classe/categoria
      - · Exemplo classificar e-mail como SPAM/HAM a partir de seu conteúdo
  - Aprendizado não-supervisionado no qual as amostras não apresentam informação extra, ou seja, desejamos buscar alguma estrutura nesses dados (aglomerar dados semelhantes e/ou determinar a distribuição de probabilidade que gerou tais dados)

## 1.1.1 Exemplo

```
In [1]: import matplotlib.pyplot as plt
       %matplotlib inline
       plt.rcParams['figure.figsize'] = (10, 8)
In [2]: from sklearn.datasets import load_boston
        boston = load_boston()
       plt.scatter(boston.data[:,5], boston.target)
       plt.xlabel(u'RM (número médio de cômodos)')
       plt.ylabel(u'Valor médio (em US$ 1.000)')
       plt.title('Boston House Prices dataset')
```





### 1.2 Scikit-learn (ou Sklearn)

• Scikit-learn é um pacote de software para aprendizado de máquina em Python

- Desenvolvida sobre a pilha de software SciPy
- Seu desenvolvimento é liderado por pesquisadores do INRIA (França)

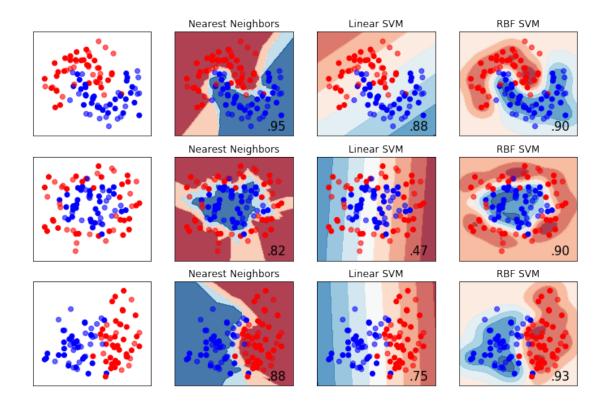
### 1.2.1 Aprendizado supervisionado na Sklearn

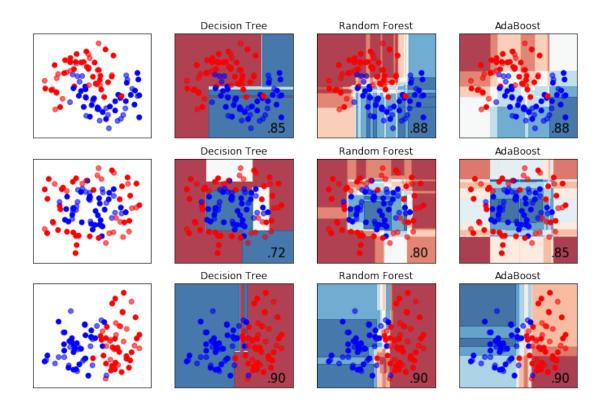
- Nearest Neighbors
- Support Vector Machines (SVM)
  - Linear Support
  - Radial Basis Function (RGB) kernel SVM
- Decision Trees
- Ensemble
  - Random Forests
  - AdaBoost
- Linear Discriminant Analysis
- Gaussian Processes

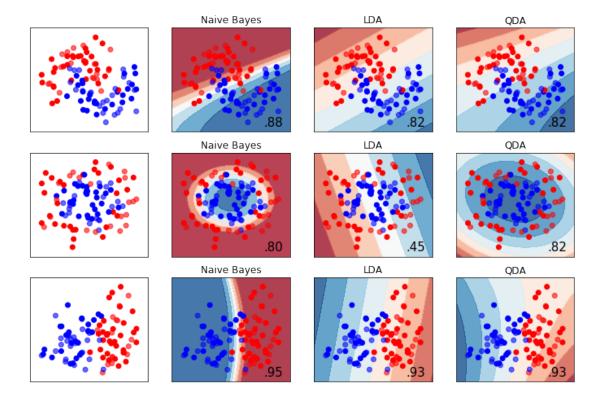
```
In [3]: # Code source: Gaël Varoquaux
              Andreas Müller
        # Modified for documentation by Jaques Grobler
        # License: BSD 3 clause
        import numpy as np
        from matplotlib.colors import ListedColormap
        from sklearn.cross_validation import train_test_split
        from sklearn.preprocessing import StandardScaler
        from sklearn.datasets import make_moons, make_circles, make_classification
        from sklearn.neighbors import KNeighborsClassifier
        from sklearn.svm import SVC
        from sklearn.tree import DecisionTreeClassifier
        from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier
        from sklearn.naive_bayes import GaussianNB
        from sklearn.discriminant_analysis import LinearDiscriminantAnalysis as LDA
        from sklearn.discriminant_analysis import QuadraticDiscriminantAnalysis as QDA
        def classifier_showroom(names, classifiers):
           h = .02 # step size in the mesh
            X, y = make_classification(n_features=2, n_redundant=0, n_informative=2,
                                   random_state=1, n_clusters_per_class=1)
            rng = np.random.RandomState(2)
            X += 2 * rng.uniform(size=X.shape)
            linearly_separable = (X, y)
            datasets = [make_moons(noise=0.3, random_state=0),
                        make_circles(noise=0.2, factor=0.5, random_state=1),
```

```
linearly_separable
figure = plt.figure(figsize=(12, 8))
i = 1
# iterate over datasets
for ds in datasets:
    # preprocess dataset, split into training and test part
    X, y = ds
    X = StandardScaler().fit_transform(X)
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=.4)
    x_{min}, x_{max} = X[:, 0].min() - .5, X[:, 0].max() + .5
    y_{min}, y_{max} = X[:, 1].min() - .5, X[:, 1].max() + .5
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                         np.arange(y_min, y_max, h))
    # just plot the dataset first
    cm = plt.cm.RdBu
    cm_bright = ListedColormap(['#FF0000', '#0000FF'])
    ax = plt.subplot(len(datasets), len(classifiers) + 1, i)
    # Plot the training points
    ax.scatter(X_train[:, 0], X_train[:, 1], c=y_train, cmap=cm_bright)
    # and testing points
    ax.scatter(X_test[:, 0], X_test[:, 1], c=y_test, cmap=cm_bright, alpha=0.6)
    ax.set_xlim(xx.min(), xx.max())
    ax.set_ylim(yy.min(), yy.max())
    ax.set_xticks(())
    ax.set_yticks(())
    i += 1
    # iterate over classifiers
    for name, clf in zip(names, classifiers):
        ax = plt.subplot(len(datasets), len(classifiers) + 1, i)
        clf.fit(X_train, y_train)
        score = clf.score(X_test, y_test)
        # Plot the decision boundary. For that, we will assign a color to each
        # point in the mesh [x_min, m_max]x[y_min, y_max].
        if hasattr(clf, "decision_function"):
            Z = clf.decision_function(np.c_[xx.ravel(), yy.ravel()])
        else:
            Z = clf.predict_proba(np.c_[xx.ravel(), yy.ravel()])[:, 1]
        # Put the result into a color plot
        Z = Z.reshape(xx.shape)
        ax.contourf(xx, yy, Z, cmap=cm, alpha=.8)
```

```
# Plot also the training points
                    ax.scatter(X_train[:, 0], X_train[:, 1], c=y_train, cmap=cm_bright)
                    # and testing points
                    ax.scatter(X_test[:, 0], X_test[:, 1], c=y_test, cmap=cm_bright,
                               alpha=0.6)
                    ax.set_xlim(xx.min(), xx.max())
                    ax.set_ylim(yy.min(), yy.max())
                    ax.set_xticks(())
                    ax.set_yticks(())
                    ax.set_title(name)
                    ax.text(xx.max() - .3, yy.min() + .3, ('%.2f' % score).lstrip('0'),
                            size=15, horizontalalignment='right')
                    i += 1
            figure.subplots_adjust(left=.02, right=.98)
/usr/local/lib/python2.7/dist-packages/sklearn/cross_validation.py:41: DeprecationWarning: This
  "This module will be removed in 0.20.", DeprecationWarning)
In [4]: names = ["Nearest Neighbors", "Linear SVM", "RBF SVM"]
        classifiers = [
            KNeighborsClassifier(3),
            SVC(kernel="linear", C=0.025),
            SVC(gamma=2, C=1)]
        classifier_showroom(names, classifiers)
```







# 1.2.2 Aprendizado não-supervisionado na Sklearn

- Gaussian mixture models
- Clustering
  - Affinity propagation
  - Mean-shift
  - Spectral clustering
  - Hierarchical clustering
  - DBSCAN
- Neural Networks (unsupervised)
  - Restricted Boltzmann machines

# In [7]: def clustering\_showroom():

```
import time

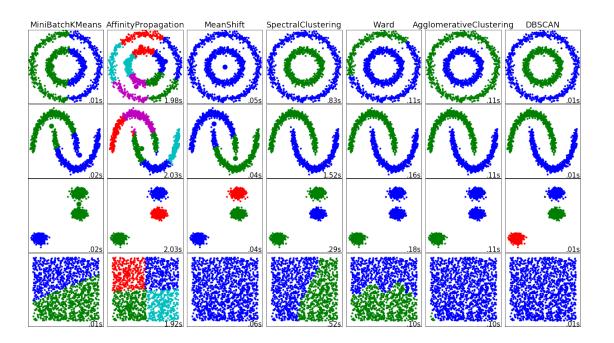
import numpy as np
import matplotlib.pyplot as plt

from sklearn import cluster, datasets
from sklearn.metrics import euclidean_distances
```

```
from sklearn.neighbors import kneighbors_graph
from sklearn.preprocessing import StandardScaler
np.random.seed(0)
# Generate datasets. We choose the size big enough to see the scalability
# of the algorithms, but not too big to avoid too long running times
n_samples = 1500
noisy_circles = datasets.make_circles(n_samples=n_samples, factor=.5,
                                      noise=.05)
noisy_moons = datasets.make_moons(n_samples=n_samples, noise=.05)
blobs = datasets.make_blobs(n_samples=n_samples, random_state=8)
no_structure = np.random.rand(n_samples, 2), None
colors = np.array([x for x in 'bgrcmykbgrcmykbgrcmykbgrcmyk'])
colors = np.hstack([colors] * 20)
plt.figure(figsize=(17, 9.5))
plt.subplots_adjust(left=.001, right=.999, bottom=.001, top=.96, wspace=.05,
                    hspace=.01)
plot_num = 1
for i_dataset, dataset in enumerate([noisy_circles, noisy_moons, blobs,
                                     no_structure]):
    X, y = dataset
    # normalize dataset for easier parameter selection
    X = StandardScaler().fit_transform(X)
    # estimate bandwidth for mean shift
    bandwidth = cluster.estimate_bandwidth(X, quantile=0.3)
    # connectivity matrix for structured Ward
    connectivity = kneighbors_graph(X, n_neighbors=10)
    # make connectivity symmetric
    connectivity = 0.5 * (connectivity + connectivity.T)
    # Compute distances
    #distances = np.exp(-euclidean_distances(X))
    distances = euclidean_distances(X)
    # create clustering estimators
    ms = cluster.MeanShift(bandwidth=bandwidth, bin_seeding=True)
    two_means = cluster.MiniBatchKMeans(n_clusters=2)
    ward = cluster.AgglomerativeClustering(n_clusters=2,
                    linkage='ward', connectivity=connectivity)
    spectral = cluster.SpectralClustering(n_clusters=2,
                                          eigen_solver='arpack',
                                          affinity="nearest_neighbors")
```

```
dbscan = cluster.DBSCAN(eps=.2)
                affinity_propagation = cluster.AffinityPropagation(damping=.9,
                                                                    preference=-200)
                average_linkage = cluster.AgglomerativeClustering(linkage="average",
                                         affinity="cityblock", n_clusters=2,
                                        connectivity=connectivity)
                for name, algorithm in [
                                         ('MiniBatchKMeans', two_means),
                                         ('AffinityPropagation', affinity_propagation),
                                         ('MeanShift', ms),
                                         ('SpectralClustering', spectral),
                                         ('Ward', ward),
                                         ('AgglomerativeClustering', average_linkage),
                                         ('DBSCAN', dbscan)
                    # predict cluster memberships
                    t0 = time.time()
                    algorithm.fit(X)
                    t1 = time.time()
                    if hasattr(algorithm, 'labels_'):
                        y_pred = algorithm.labels_.astype(np.int)
                    else:
                        y_pred = algorithm.predict(X)
                    # plot
                    plt.subplot(4, 7, plot_num)
                    if i dataset == 0:
                        plt.title(name, size=18)
                    plt.scatter(X[:, 0], X[:, 1], color=colors[y_pred].tolist(), s=10)
                    if hasattr(algorithm, 'cluster_centers_'):
                        centers = algorithm.cluster_centers_
                        center_colors = colors[:len(centers)]
                        plt.scatter(centers[:, 0], centers[:, 1], s=100, c=center_colors)
                    plt.xlim(-2, 2)
                    plt.ylim(-2, 2)
                    plt.xticks(())
                    plt.yticks(())
                    plt.text(.99, .01, ('%.2fs' % (t1 - t0)).lstrip('0'),
                             transform=plt.gca().transAxes, size=15,
                             horizontalalignment='right')
                    plot_num += 1
            plt.show()
In [8]: clustering_showroom()
```

- /usr/local/lib/python2.7/dist-packages/pyamg/\_\_init\_\_.py:54: UserWarning: SciPy 0.7 or above is UserWarning)
- /usr/local/lib/python2.7/dist-packages/pyamg/\_\_init\_\_.py:54: UserWarning: SciPy 0.7 or above is UserWarning)
- /usr/local/lib/python2.7/dist-packages/sklearn/manifold/spectral\_embedding\_.py:234: UserWarning: warnings.warn("Graph is not fully connected, spectral embedding"
- /usr/local/lib/python2.7/dist-packages/sklearn/cluster/hierarchical.py:193: UserWarning: the num affinity='euclidean')
- /usr/local/lib/python2.7/dist-packages/sklearn/cluster/hierarchical.py:426: UserWarning: the numaffinity=affinity)
- /usr/local/lib/python2.7/dist-packages/pyamg/\_\_init\_\_.py:54: UserWarning: SciPy 0.7 or above is UserWarning)
- /usr/local/lib/python2.7/dist-packages/sklearn/cluster/hierarchical.py:193: UserWarning: the numaffinity='euclidean')
- /usr/local/lib/python2.7/dist-packages/sklearn/cluster/hierarchical.py:426: UserWarning: the numaffinity=affinity)
- /usr/local/lib/python2.7/dist-packages/pyamg/\_\_init\_\_.py:54: UserWarning: SciPy 0.7 or above is UserWarning)



#### 1.2.3 Fit/Predict

- Na Sklearn, os algoritmos são representados por objetos (POO)
- Tais objetos implementam uma interface fit/predict
- fit
  - realiza a etapa de aprendizado

- predict
  - realiza as etapas de regressão ou classificação
- O **modelo** aprendido pode ser armazenado em disco utilizando o módulo de persistência pickle

## 1.3 Instalação da Sklearn

- Usuários Windows e Mac deveriam considerar a distribuição Anaconda da Continuum Analytics
- Usuários Linux podem utilizar o gerenciador de pacotes de sua distribuição
  - Exemplo: usuários Debian/Ubuntu podem utilizar \$ sudo apt-get install python-sklearn
- Usuários de todos os sistemas podem utilizar o pip \$ pip install scikit-learn
- Instruções detalhadas de instalação podem ser vistas no site oficial da Sklearn.

#### 1.4 Sobre este curso

- Este é um curso **introdutório** sobre a sklearn
- Sua função é fornecer alguns exemplos ilustrativos e referências para aqueles interessados em trabalhar com aprendizado de máquina em Python
- Todo o material do curso encontra-se disponível na forma de **notebooks IPython** no GitHub
  - https://github.com/thsant/sklearn-intro

## 1.5 Visão geral da Sklearn

http://scikit-learn.org/stable/tutorial/machine\_learning\_map/index.html