

Scikit-learn – Introdução

Thiago Teixeira Santos
thiago.santos@embrapa.br

24 de novembro de 2017

Para uma visão mais detalhada e aprofundada, considere [scikit-learn: machine learning in Python](#), escrito por Gael Varoquaux, e [An introduction to machine learning with scikit-learn](#), parte da documentação oficial da Scikit-learn.

1 Scikit-learn

1.1 Introdução

- Há um conjunto de técnicas de **aprendizado** e **inferência** que inclui
 - Regressão Linear
 - Regressão Logística
 - Clustering (diversos algoritmos)
 - Máquinas de vetores de suporte
 - Processos Gaussianos
 - PCA/LDA
 - etc.
- Tais técnicas apresentam nomes diferentes em comunidades diferentes
 - Cientistas da Computação e engenheiros chamam de **aprendizado de máquina**
 - Economistas chamam de **econometria**
 - Estatísticos de **aprendizado estatístico de padrões**
 - Bioinformatas de **bioestatística**

1.1.1 Qual é a tarefa em questão?

- Essas técnicas tentam resolver um **problema de aprendizado**: dadas **n amostras** de dados, **prever** as propriedades de dados não observados
- Problemas de aprendizado são geralmente divididos em 2 casos:
 - **Aprendizado supervisionado** - no qual as amostras apresentam informação extra sobre a propriedade a ser prevista
 - * Regressão - a propriedade a ser prevista é um valor contínuo
 - *Exemplo* - o preço de uma casa a partir de dados de localização, cômodos, vizinhança, etc.
 - * Classificação - a propriedade a ser prevista é uma classe/categoria

- *Exemplo* - classificar e-mail como SPAM/HAM a partir de seu conteúdo
- **Aprendizado não-supervisionado** - no qual as amostras não apresentam informação extra, ou seja, desejamos buscar alguma **estrutura** nesses dados (aglomerar dados semelhantes e/ou determinar a distribuição de probabilidade que gerou tais dados)

Exemplo

```
In [1]: # Importa o módulo de plotagem
import matplotlib.pyplot as plt

# Configura a matplotlib para operar interativamente no notebook. Para detalhes, execute
# %matplotlib?
%matplotlib inline

# Configura o tamanho padrão da figura largura X altura, em polegadas
plt.rcParams['figure.figsize'] = (10, 8)

In [2]: # Apenas para evitar problemas de visualização nos slides. NÃO use isto de forma regular
import warnings
warnings.filterwarnings('ignore')
```

1.1.2 Scikit-learn (ou Sklearn)

- Scikit-learn é um pacote de software para aprendizado de máquina em **Python**
- Desenvolvida sobre a *pilha de software* SciPy
- Seu desenvolvimento é liderado por pesquisadores do INRIA (França)

Aprendizado supervisionado na Sklearn

- Nearest Neighbors
- Support Vector Machines (SVM)
 - Linear Support
 - Radial Basis Function (RBF) kernel SVM
- Decision Trees
- Ensemble
 - Random Forests
 - AdaBoost
- Linear Discriminant Analysis
- Gaussian Processes

```
In [3]: # Code source: Gaël Varoquaux
#           Andreas Müller
# Modified for documentation by Jaques Grobler
# Modified for this course by Thiago Santos
# License: BSD 3 clause
```

```

import numpy as np
from matplotlib.colors import ListedColormap
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.datasets import make_moons, make_circles, make_classification
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis as LDA
from sklearn.discriminant_analysis import QuadraticDiscriminantAnalysis as QDA

def classifier_showroom(names, classifiers):

    h = .02 # step size in the mesh

    X, y = make_classification(n_features=2, n_redundant=0, n_informative=2,
                              random_state=1, n_clusters_per_class=1)
    rng = np.random.RandomState(2)
    X += 2 * rng.uniform(size=X.shape)
    linearly_separable = (X, y)

    datasets = [make_moons(noise=0.3, random_state=0),
                make_circles(noise=0.2, factor=0.5, random_state=1),
                linearly_separable
                ]

    figure = plt.figure(figsize=(12, 8))
    i = 1
    # iterate over datasets
    for ds in datasets:
        # preprocess dataset, split into training and test part
        X, y = ds
        X = StandardScaler().fit_transform(X)
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=.4)

        x_min, x_max = X[:, 0].min() - .5, X[:, 0].max() + .5
        y_min, y_max = X[:, 1].min() - .5, X[:, 1].max() + .5
        xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                              np.arange(y_min, y_max, h))

        # just plot the dataset first
        cm = plt.cm.RdBu
        cm_bright = ListedColormap(['#FF0000', '#0000FF'])
        ax = plt.subplot(len(datasets), len(classifiers) + 1, i)
        # Plot the training points
        ax.scatter(X_train[:, 0], X_train[:, 1], c=y_train, cmap=cm_bright)

```

```

# and testing points
ax.scatter(X_test[:, 0], X_test[:, 1], c=y_test, cmap=cm_bright, alpha=0.6)
ax.set_xlim(xx.min(), xx.max())
ax.set_ylim(yy.min(), yy.max())
ax.set_xticks(())
ax.set_yticks(())
i += 1

# iterate over classifiers
for name, clf in zip(names, classifiers):
    ax = plt.subplot(len(datasets), len(classifiers) + 1, i)
    clf.fit(X_train, y_train)
    score = clf.score(X_test, y_test)

    # Plot the decision boundary. For that, we will assign a color to each
    # point in the mesh [x_min, m_max][y_min, y_max].
    if hasattr(clf, "decision_function"):
        Z = clf.decision_function(np.c_[xx.ravel(), yy.ravel()])
    else:
        Z = clf.predict_proba(np.c_[xx.ravel(), yy.ravel()])[:, 1]

    # Put the result into a color plot
    Z = Z.reshape(xx.shape)
    ax.contourf(xx, yy, Z, cmap=cm, alpha=.8)
    if hasattr(clf, "decision_function"):
        ax.contour(xx, yy, Z, [0.0], colors='k', linestyle=['solid'])
    else:
        ax.contour(xx, yy, Z, [0.5], colors='k', linestyle=['solid'])

    # Plot also the training points
    ax.scatter(X_train[:, 0], X_train[:, 1], c=y_train, cmap=cm_bright)
    # and testing points
    ax.scatter(X_test[:, 0], X_test[:, 1], c=y_test, cmap=cm_bright,
              alpha=0.6)

    ax.set_xlim(xx.min(), xx.max())
    ax.set_ylim(yy.min(), yy.max())
    ax.set_xticks(())
    ax.set_yticks(())
    ax.set_title(name)
    ax.text(xx.max() - .3, yy.min() + .3, ('%.2f' % score).lstrip('0'),
          size=15, horizontalalignment='right')
    i += 1

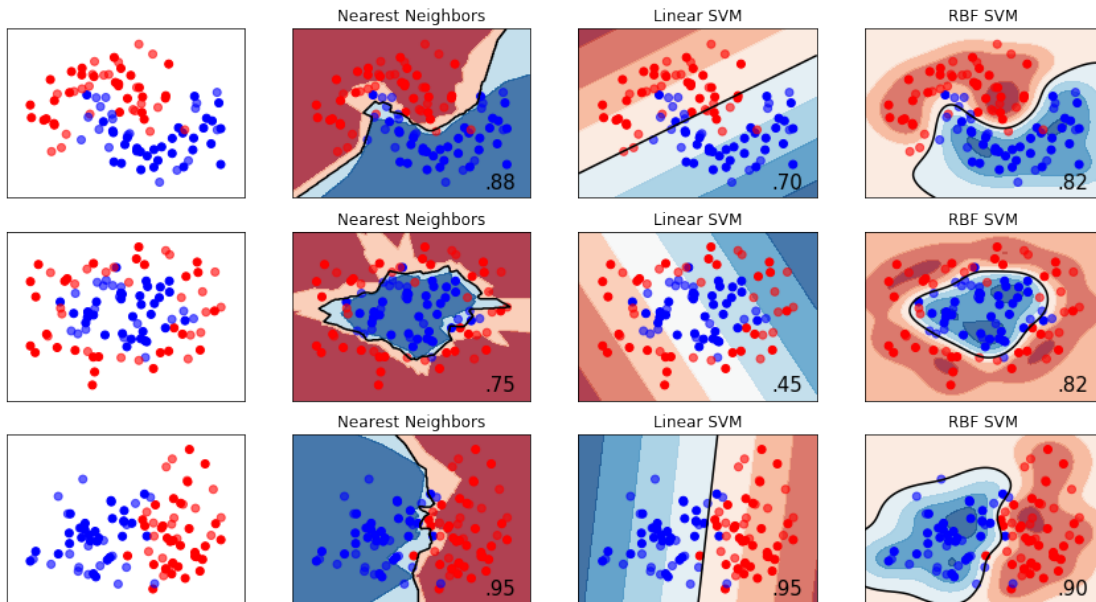
```

```
figure.subplots_adjust(left=.02, right=.98)
```

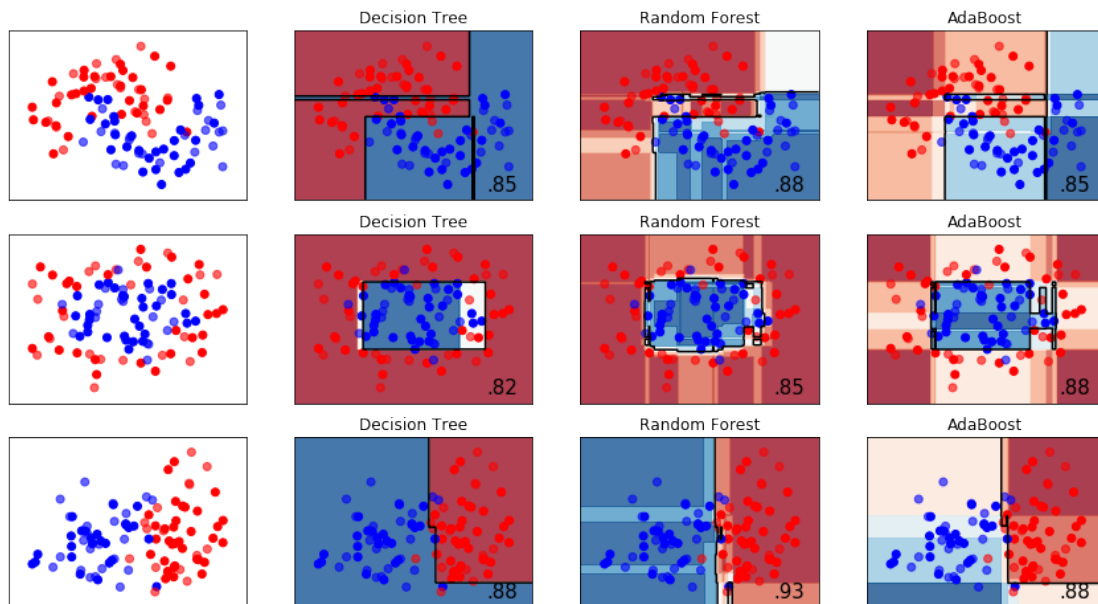
```
In [4]: names = ["Nearest Neighbors", "Linear SVM", "RBF SVM"]
        classifiers = [
```

```
KNeighborsClassifier(3),
SVC(kernel="linear", C=0.025),
SVC(gamma=2, C=1)]
```

```
classifier_showroom(names, classifiers)
```

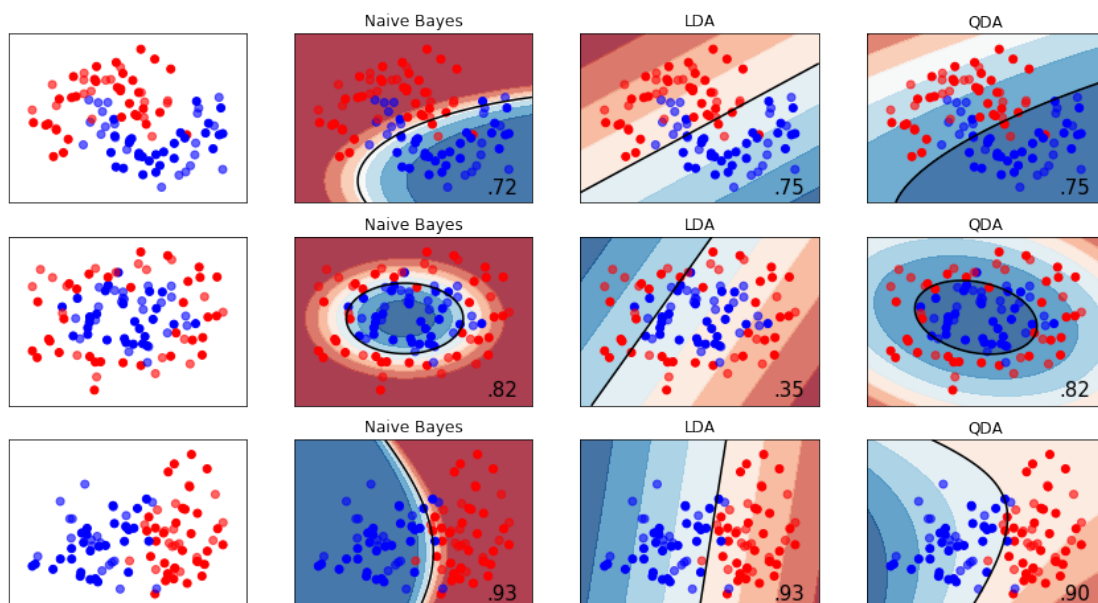


```
In [5]: names = ["Decision Tree", "Random Forest", "AdaBoost"]
classifiers = [
    DecisionTreeClassifier(max_depth=5),
    RandomForestClassifier(max_depth=5, n_estimators=10, max_features=1),
    AdaBoostClassifier()]
classifier_showroom(names, classifiers)
```



```
In [6]: names = ["Naive Bayes", "LDA", "QDA"]
        classifiers = [
            GaussianNB(),
            LDA(),
            QDA()]

        classifier_showroom(names, classifiers)
```



Aprendizado não-supervisionado na Sklearn

- Gaussian mixture models
- Clustering
 - Affinity propagation
 - Mean-shift
 - Spectral clustering
 - Hierarchical clustering
 - DBSCAN
- Neural Networks (unsupervised)
 - Restricted Boltzmann machines

```
In [7]: def clustering_showroom():

    import time

    import numpy as np
    import matplotlib.pyplot as plt

    from sklearn import cluster, datasets
    from sklearn.metrics import euclidean_distances
    from sklearn.neighbors import kneighbors_graph
    from sklearn.preprocessing import StandardScaler

    np.random.seed(0)

    # Generate datasets. We choose the size big enough to see the scalability
    # of the algorithms, but not too big to avoid too long running times
    n_samples = 1500
    noisy_circles = datasets.make_circles(n_samples=n_samples, factor=.5,
                                          noise=.05)
    noisy_moons = datasets.make_moons(n_samples=n_samples, noise=.05)
    blobs = datasets.make_blobs(n_samples=n_samples, random_state=8)
    no_structure = np.random.rand(n_samples, 2), None

    colors = np.array([x for x in 'bgrcmykbgrcmykbgrcmykbgrcmyk'])
    colors = np.hstack([colors] * 20)

    plt.figure(figsize=(17, 9.5))
    plt.subplots_adjust(left=.001, right=.999, bottom=.001, top=.96, wspace=.05,
                        hspace=.01)

    plot_num = 1
    for i_dataset, dataset in enumerate([noisy_circles, noisy_moons, blobs,
                                         no_structure]):

        X, y = dataset
        # normalize dataset for easier parameter selection
```

```

X = StandardScaler().fit_transform(X)

# estimate bandwidth for mean shift
bandwidth = cluster.estimate_bandwidth(X, quantile=0.3)

# connectivity matrix for structured Ward
connectivity = kneighbors_graph(X, n_neighbors=10)
# make connectivity symmetric
connectivity = 0.5 * (connectivity + connectivity.T)

# Compute distances
#distances = np.exp(-euclidean_distances(X))
distances = euclidean_distances(X)

# create clustering estimators
ms = cluster.MeanShift(bandwidth=bandwidth, bin_seeding=True)
two_means = cluster.MinibatchKMeans(n_clusters=2)
ward = cluster.AgglomerativeClustering(n_clusters=2,
                                       linkage='ward', connectivity=connectivity)
spectral = cluster.SpectralClustering(n_clusters=2,
                                     eigen_solver='arpack',
                                     affinity="nearest_neighbors")

dbscan = cluster.DBSCAN(eps=.2)
affinity_propagation = cluster.AffinityPropagation(damping=.9,
                                                    preference=-200)

average_linkage = cluster.AgglomerativeClustering(linkage="average",
                                                  affinity="cityblock", n_clusters=2,
                                                  connectivity=connectivity)

for name, algorithm in [
    ('MiniBatchKMeans', two_means),
    ('AffinityPropagation', affinity_propagation),
    ('MeanShift', ms),
    ('SpectralClustering', spectral),
    ('Ward', ward),
    ('AgglomerativeClustering', average_linkage),
    ('DBSCAN', dbscan)
]:
    # predict cluster memberships
    t0 = time.time()
    algorithm.fit(X)
    t1 = time.time()
    if hasattr(algorithm, 'labels_'):
        y_pred = algorithm.labels_.astype(np.int)
    else:
        y_pred = algorithm.predict(X)

```



```

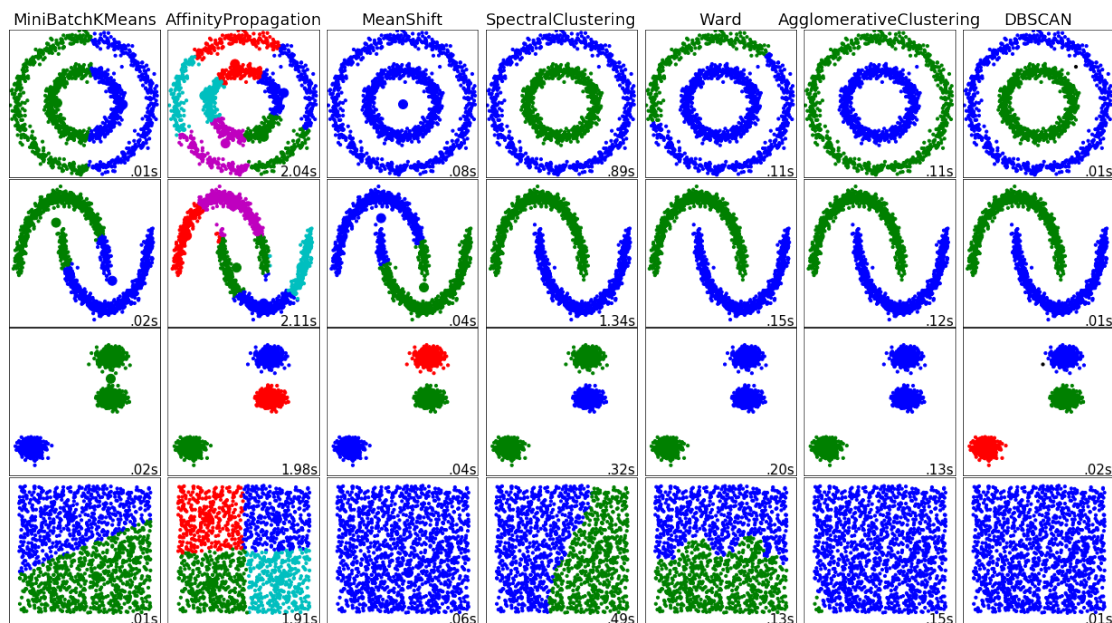
# plot
plt.subplot(4, 7, plot_num)
if i_dataset == 0:
    plt.title(name, size=18)
plt.scatter(X[:, 0], X[:, 1], color=colors[y_pred].tolist(), s=10)

if hasattr(algorithm, 'cluster_centers_'):
    centers = algorithm.cluster_centers_
    center_colors = colors[:len(centers)]
    plt.scatter(centers[:, 0], centers[:, 1], s=100, c=center_colors)
plt.xlim(-2, 2)
plt.ylim(-2, 2)
plt.xticks(())
plt.yticks(())
plt.text(.99, .01, ('%.2fs' % (t1 - t0)).lstrip('0'),
         transform=plt.gca().transAxes, size=15,
         horizontalalignment='right')
plot_num += 1

plt.show()

```

In [8]: clustering_showroom()



Fit/Predict

- Na Sklearn, os algoritmos são representados por objetos (POO)
- Tais objetos implementam uma **interface fit/predict**

- `fit`
 - realiza a etapa de **aprendizado**
- `predict`
 - realiza as etapas de regressão ou classificação
- O **modelo** aprendido pode ser armazenado em disco utilizando o módulo de persistência `pickle`

1.1.3 Instalação da Sklearn

- Usuários Windows e Mac deveriam considerar a [distribuição Anaconda](#) da Continuum Analytics
- Usuários Linux podem utilizar o gerenciador de pacotes de sua distribuição
 - *Exemplo:* usuários Debian/Ubuntu podem utilizar `$ sudo apt-get install python-sklearn`
- Usuários de todos os sistemas podem utilizar o `pip` `$ pip install scikit-learn`
- [Instruções detalhadas de instalação](#) podem ser vistas no site oficial da Sklearn.